Trabajo Práctico Evaluativo Nº 1

Proceso KDD Completo con Datasets Públicos - Modelos de Regresión

1. Dominio del problema

El control de calidad en la industria vitivinícola tradicionalmente depende de la evaluación sensorial de catadores expertos (panel de cata), un proceso subjetivo, costoso y difícil de escalar. Sin embargo, la calidad final de un vino está fuertemente influenciada por sus propiedades fisicoquímicas, que sí pueden medirse de forma objetiva y automatizada en laboratorio (acidez, azúcar residual, sulfatos, alcohol, etc.).

El objetivo de este trabajo es construir y comparar dos modelos de regresión que estimen el puntaje de calidad de un vino (variable continua) a partir de sus variables fisicoquímicas:

- Regresión Lineal Múltiple: modela quality como una combinación lineal de las variables predictoras.
- Árbol de Decisión de Regresión: modela la misma variable continua mediante particiones sucesivas del espacio de variables, capturando relaciones no lineales.

Todo el trabajo debe desarrollarse siguiendo el proceso KDD (Knowledge Discovery in Databases) de forma explícita, documentando y justificando cada decisión tomada en cada etapa — no alcanza con obtener buenas métricas: hay que argumentar por qué se tomó cada camino.

2. El dataset

Nombre: Wine Quality Dataset (Vinho Verde tinto)

Fuente: UCI Machine Learning Repository — Cortez, P., Cerdeira, A., Almeida, F., Matos, T. y Reis, J. (2009).

Enlace de descarga oficial: https://archive.ics.uci.edu/dataset/186/wine+quality

Descarga directa del CSV: https://archive.ics.uci.edu/ml/machine-learning-databases/wine-quality/winequality-red.csv

2.1 Descripción

El dataset contiene 1.599 muestras de vino tinto portugués ("Vinho Verde"), cada una descripta por 11 variables fisicoquímicas de entrada y una variable de salida ("quality") que representa la mediana de las puntuaciones otorgadas por al menos 3 catadores expertos, en una escala de 0 (muy malo) a 10 (excelente).

2.2 Variables

Variable	Descripción	Tipo
fixed acidity	Acidez fija (ácidos no volátiles, g/dm³)	Numérica continua
volatile acidity	Acidez volátil — en exceso genera sabor a vinagre (g/dm³)	Numérica continua
citric acid	Ácido cítrico — aporta frescura (g/dm³)	Numérica continua
residual sugar	Azúcar residual tras la fermentación (g/dm³)	Numérica continua
chlorides	Contenido de sal (g/dm³)	Numérica continua
free sulfur dioxide	SO_2 libre — previene crecimiento microbiano (mg/dm³)	Numérica continua

Variable	Descripción	Tipo
total sulfur dioxide	SO_2 total (mg/dm³)	Numérica continua
density	Densidad del vino (g/cm³)	Numérica continua
pH	Nivel de acidez/alcalinidad (0-14)	Numérica continua
sulphates	Sulfatos — antioxidante y antimicrobiano (g/dm³)	Numérica continua
alcohol	Porcentaje de alcohol (% vol.)	Numérica continua
quality (target)	Puntaje sensorial mediano, escala 0-10 (observado: 3-8)	Numérica discreta / ordinal

3. Marco de trabajo: el proceso KDD

KDD (Knowledge Discovery in Databases) es el proceso integral para extraer conocimiento útil a partir de datos crudos. Este trabajo debe organizarse explícitamente en las siguientes etapas:

Etapa KDD	Qué implica en este trabajo
1. Selección	Elegir y cargar el dataset público adecuado al problema de negocio planteado.
2. Preprocesamiento / Limpieza	Detectar valores nulos, filas duplicadas y outliers; decidir y justificar cómo tratar cada caso.
3. Transformación	Separar variables predictoras y objetivo, dividir en entrenamiento/prueba, escalar si corresponde.
4. Minería de datos	Aplicar los algoritmos de regresión elegidos (Regresión Lineal y Árbol de Decisión de Regresión).
5. Interpretación / Evaluación	Calcular métricas (MAE, RMSE, R^2), analizar sobreajuste, interpretar coeficientes e importancias.
6. Conocimiento / Selección del modelo	Comparar los modelos, justificar la elección final y documentar las conclusiones.

4. Actividades a resolver

Etapa 1 — Selección de datos

1. Descargar el dataset desde el enlace oficial y cargarlo en un DataFrame.
2. Describir su estructura: dimensiones, tipos de datos y EDA desde el punto de vista de las estadísticas descriptivas (media, desvío, mínimo, máximo) de cada variable.

Etapa 2 — Preprocesamiento y limpieza

3. Estadarizar mayúsculas/minusculas
4. Verificar la presencia de valores nulos en el dataset. Decidir como tratarlos y justificar la desición.
5. Verificar la presencia de filas duplicadas exactas. En caso de encontrarlas, decidir si corresponde eliminarlas antes de dividir en entrenamiento y prueba, y justificar la decisión.

6. Detectar outliers en cada variable mediante el método del rango intercuartílico (IQR). Decidir y justificar si conviene eliminarlos, transformarlos o conservarlos, considerando el dominio del problema.
7. Se considera necesario realizar la unificación/estandarización de unidaddes y formatos
8. Documentar el tamaño final del dataset luego de aplicar las decisiones de limpieza.

Etapa 3 — Transformación de datos

9. Separar las variables predictoras (X) de la variable objetivo quality (y).
10. Dividir el dataset en conjunto de entrenamiento (80%) y prueba (20%).
11. Decidir si es necesario escalar las variables predictoras (por ejemplo, con StandardScaler) para cada uno de los dos algoritmos a utilizar, y justificar la decisión en cada caso.

Etapa 4 — Minería de datos: aplicación de los modelos

12. Entrenar un modelo de Regresión Lineal Múltiple sobre el conjunto de entrenamiento.
13. Entrenar un Árbol de Decisión de Regresión (DecisionTreeRegressor), probando al menos tres profundidades máximas distintas (por ejemplo, 3, 5 y sin límite).

Etapa 5 — Interpretación y evaluación de resultados

14. Calcular MAE, RMSE y R^2 de la Regresión Lineal sobre el conjunto de prueba.
15. Calcular MAE, RMSE y R^2 del Árbol de Decisión sobre entrenamiento y prueba, para cada profundidad probada. Analizar cómo cambia la brecha entre ambos conjuntos a medida que aumenta la profundidad, e identificar en qué punto aparece sobreajuste.
16. Analizar los coeficientes de la Regresión Lineal y la importancia de variables (feature_importances_) del árbol elegido. ¿Qué variables resultan más relevantes en cada modelo?

Etapa 6 — Selección del modelo final y conclusiones

17. Elaborar una tabla comparativa final entre la Regresión Lineal y la mejor configuración del Árbol de Decisión, usando MAE, RMSE y R^2.
18. Seleccionar el modelo final y justificar la decisión, considerando no solo las métricas sino también la interpretabilidad y la robustez de cada modelo.
19. Redactar una conclusión breve sobre qué tan bien pueden predecirse la calidad sensorial del vino a partir únicamente de variables fisicoquímicas, si se podrían plantear mejoras.

Entregable

Notebook o script (Python) con el código completo y comentado de las 6 etapas.

Informe breve (máx. 4 páginas) que documente, para cada etapa del proceso KDD, las decisiones tomadas y su justificación, junto con las tablas de métricas, gráficos relevantes (distribución de quality, matriz de correlación, curva de R^2 train/test según profundidad del árbol) y las respuestas a las preguntas de análisis de la sección 5.

5. Preguntas de análisis

20. En la etapa de preprocesamiento pueden encontrarse filas duplicadas exactas en el dataset. ¿Por qué es una buena práctica eliminarlas antes de dividir en entrenamiento y prueba? ¿Qué problema se evita al hacerlo?
21. Al aplicar el método IQR es posible detectar outliers en varias variables (con porcentajes que pueden llegar a superar el 9% en algunas de ellas). Justifiquen, considerando el dominio del problema y la

robustez de cada algoritmo frente a valores extremos, si conviene eliminarlos o conservarlos en este caso.

22. ¿Por qué es necesario escalar las variables (StandardScaler) para interpretar correctamente los coeficientes de la Regresión Lineal, pero no es estrictamente necesario para el Árbol de Decisión de Regresión?
23. Si al entrenar el árbol sin límite de profundidad obtienen un R^2 de entrenamiento cercano a 1 y un R^2 de prueba negativo, ¿qué significa un R^2 negativo y qué evidencia de sobreajuste extremo revela esa comparación?
24. Repitan la comparación final de la Etapa 6 sin haber eliminado las filas duplicadas de la Etapa 2. ¿Cambia la conclusión sobre qué modelo es mejor? Qué tanto puede depender la selección final del modelo de una decisión tomada en una etapa temprana del proceso KDD.