Proceso KDD con Wine Quality (Vinho Verde tinto): Regresión Lineal vs. Árbol de Decisión

Objetivo: estimar el puntaje de calidad (`quality`, variable continua) de un vino a partir de sus propiedades fisicoquímicas, comparando una Regresión Lineal Múltiple y un Árbol de Decisión de Regresión, y documentando y justificando cada decisión del proceso KDD.

1. Selección

Se usa el dataset Wine Quality (tinto) de UCI (Cortez et al., 2009): **1,599 muestras**, 11 predictores fisicoquímicos continuos y `quality` (mediana de ≥3 catadores, observado 3–8). Es el indicado para el problema y su target numérico permite plantear regresión. Se cargó desde el enlace oficial con `pd.read_csv(sep=';')`. **EDA (Fig. 1):** `quality` se concentra en 5 y 6 (82% de las muestras) y las clases extremas son raras, lo que dificulta predecir extremos. Las mayores correlaciones con el target son `alcohol` (r=+0.48) y `volatile_acidity` (r=-0.40). Hay multicolinealidad entre predictores (p. ej. `fixed_acidity`–`density` r=0.67; `fixed_acidity`–`ph` r=-0.69), relevante para interpretar coeficientes. Las escalas difieren mucho entre variables.

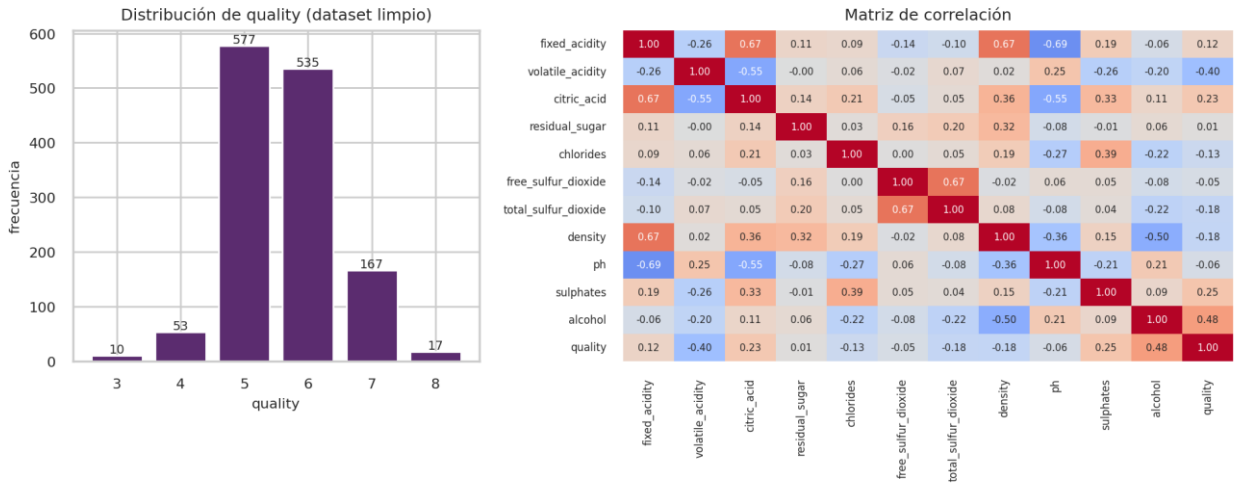


Figura 1. Distribución de quality y matriz de correlación.

2. Preprocesamiento y limpieza

- **Formato:** nombres de columnas en minúsculas y sin espacios (`fixed  acidity` → `fixed_acidity`); no hay variables de texto.
- **Nulos:** 0 → no se imputa ni se descartan filas. Los ceros de `citric_acid` son valores posibles del dominio, no faltantes.
- **Duplicados exactos:** 240 filas (15.0%). Se **eliminan antes del split** para evitar que una misma muestra quede en train y test (fuga de datos).
- **Outliers (IQR):** hasta 9.3% en `residual_sugar` y 25% de las filas con al menos uno. Se **conservan**: son valores plausibles (no errores), eliminarlos descartaría gran parte de los datos y a los vinos extremos más informativos, y el árbol es robusto a extremos. Se verificó empíricamente el efecto sobre la regresión lineal (pregunta 21).
- **Unidades/formatos:** homogéneos en cada variable (g/dm³, mg/dm³, % vol.); se verificó plausibilidad (pH en 0–14, densidad ≈1, SO_2 libre ≤ total, sin negativos). No se requiere conversión.
- **Tamaño final:** 1,599 × 12 → **1,359 × 12**.

3. Transformación

Se separan X (11 predictores) e y (`quality`) y se divide 80/20 con `random_state=42`, **estratificando por `quality`** (las clases 3 y 8 son raras) → **train = 1,087** y **test = 272**. **Escalado:** `StandardScaler` ajustado sólo con train para la **Regresión Lineal** (hace comparables los coeficientes; no altera sus predicciones). **No se escala el árbol**: elige umbrales por variable y es invariante a transformaciones monótonas.

4. Minería de datos

Se entrenó una Regresión Lineal Múltiple (sobre datos escalados) y árboles `DecisionTreeRegressor` con `max_depth` = 3, 5 y sin límite, explorando además 1–20 para la curva. La profundidad final **d = 3** se eligió por **validación cruzada de 5 folds sobre train** (R^2 CV = 0.290), no mirando el test, para mantenerlo como evaluación honesta.

5. Interpretación y evaluación

Modelo	MAE train	MAE test	RMSE train	RMSE test	R^2 train	R^2 test	Brecha R^2
Regresión Lineal	0.510	0.507	0.660	0.652	0.360	0.366	-0.006
Árbol (max_depth=3) ★ CV	0.521	0.568	0.661	0.702	0.356	0.266	0.090
Árbol (max_depth=5)	0.450	0.545	0.585	0.703	0.496	0.263	0.233
Árbol (max_depth=sin límite)	0.000	0.592	0.000	0.885	1.000	-0.167	1.167

Tabla 1. Métricas en entrenamiento y prueba (★ = profundidad elegida por validación cruzada).

Sobreajuste. La brecha de R^2 (train–test) pasa de 0.090 con profundidad 3 a 0.233 con 5 y a **1.167 sin límite** (R^2 train = 1.000; R^2 test = -0.167). En la Fig. 2, el R^2 de test alcanza su máximo cerca de la profundidad 4 y a partir de ahí deja de mejorar mientras el de train sigue subiendo: ahí **empieza el sobreajuste**. Profundidades muy bajas producen subajuste. La regresión lineal tiene una brecha mínima (-0.006).

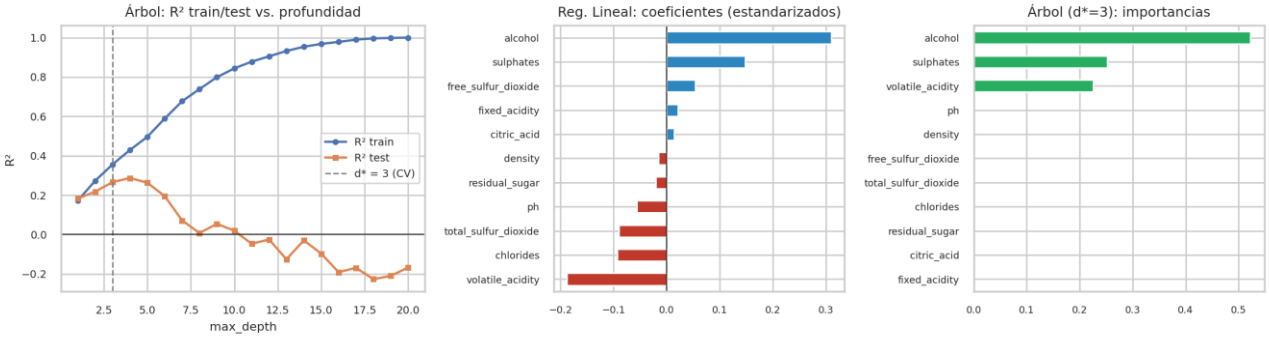


Figura 2. Curva de R^2 train/test según profundidad, coeficientes de la regresión e importancias del árbol.

Variables relevantes. Regresión Lineal (mayor |coef| estandarizado): alcohol (+0.31), volatile_acidity (-0.19), sulphates (+0.15). Árbol: alcohol (0.52), sulphates (0.25), volatile_acidity (0.23). Coinciden en `alcohol`, `sulphates`, `volatile_acidity`, lo que refuerza la conclusión. Los coeficientes de variables correlacionadas entre sí (acidez fija, densidad, pH) deben leerse con cautela por la multicolinealidad; las importancias del árbol no indican el signo del efecto.

6. Conocimiento: selección del modelo y conclusiones

Modelo	MAE test	RMSE test	R^2 test	R^2 CV (5 folds, train)
Regresión Lineal	**0.507**	**0.652**	**0.366**	**0.341 ± 0.028**
Árbol (max_depth=3)	0.568	0.702	0.266	0.290 ± 0.056

Tabla 2. Comparación final en el conjunto de prueba (fila resaltada = modelo elegido).

Modelo final: Regresión Lineal Múltiple. (Regla: se elige el árbol sólo si mejora el R^2 de test en más de 0,02 y también la CV; si no, se prefiere el modelo más simple.) El árbol no supera de forma clara y consistente a la regresión (R^2 test 0.266 vs. 0.366; R^2 CV 0.290 vs. 0.341). Con métricas similares se prefiere la regresión por **parsimonia**: es más simple, **interpretable** (cada coeficiente da signo y magnitud del efecto), **más estable** (desvío en CV 0.028 vs. 0.056) y con brecha train–test mínima (-0.006 vs. 0.090).

Conclusión. El modelo final logra R^2 = 0.366, MAE = 0.507 y RMSE = 0.652: las variables fisicoquímicas explican aproximadamente el 37% de la variabilidad de `quality`, es decir, **capacidad predictiva moderada**. El resto se debe a factores no medidos (variedad de uva, añada, terroir, aromas), a la subjetividad del panel de cata y a que el target es discreto y concentrado en 5–6. **Mejoras posibles:** transformaciones (log) de variables asimétricas, interacciones, regularización (Ridge/Lasso), ensambles (Random Forest, Gradient Boosting), plantear el problema como clasificación (baja/media/alta), validación cruzada repetida y más variables/datos en los extremos.

7. Respuestas a las preguntas de análisis

Pregunta 20 – Duplicados antes del split. Si se dividen con duplicados, una misma muestra puede caer en train y en test (data leakage): el test deja de ser independiente, las métricas se inflan y se favorece a los modelos que memorizan. Aquí había 240 duplicados (15.0%) y, con ellos, el 23.8% de las filas de test tenía una copia exacta en train (vs. 0.0% tras deduplicar).

Pregunta 21 – Outliers. Se conservan: son valores plausibles del dominio, quitarlos eliminaría 25% de las filas (y a los vinos extremos), y el árbol es robusto a extremos (la regresión lineal es más sensible). Verificación: quitarlos sólo del train cambia el R^2 de test de 0.366 a 0.258 en la regresión lineal y de 0.266 a 0.311 en el árbol; aunque hay cierta mejora, no compensa la pérdida de información; una alternativa es transformar (log) o usar modelos robustos.

Pregunta 22 – Escalado. El coeficiente es el cambio en `quality` por unidad de cada variable; con unidades dispares (`density` varía ≈0,01 y `total_sulfur_dioxide` ≈280) no son comparables. Estandarizadas, cada coeficiente es el cambio por 1 desvío y sus magnitudes se comparan (las predicciones no cambian: verificado). El árbol decide por umbrales sobre una variable a la vez, invariantes a transformaciones monótonas: mismas particiones, predicciones e importancias con o sin escalar (verificado).

Pregunta 23 – R^2 negativo. Un **R^2 negativo** indica que el modelo predice **peor que la media** (SS_res > SS_tot). Con R^2 train = 1.000 y test = -0.167, el árbol sin límite memorizó el entrenamiento (una hoja por observación) y no generaliza: **sobreajuste extremo** (varianza muy alta).

Pregunta 24 – Sin eliminar duplicados (pipeline completo repetido; Tabla 3).

Modelo (test)	RMSE limpio	RMSE con dup.	R^2 limpio	R^2 con dup.
Regresión Lineal	0.652	0.637	0.366	0.370
Árbol podado (CV)	0.702	0.704	0.266	0.232
Árbol sin límite	0.885	0.750	-0.167	0.128

Tabla 3. Comparación con y sin eliminar duplicados.

El mejor modelo por R^2 de test es **Regresión Lineal** con datos limpios y **Regresión Lineal** con duplicados: la conclusión sobre qué modelo es mejor **no cambia**. El R^2 del árbol sin límite pasa de -0.167 a 0.128 y el de la regresión de 0.366 a 0.370: los modelos que memorizan son los más beneficiados por la fuga, una ventaja artificial que no se sostendría en producción.
Moraleja KDD: una decisión temprana de limpieza puede alterar las métricas, el ranking de modelos y la confianza en las conclusiones; por eso se documenta y se hace antes de particionar. Conviene repetir con varias semillas o CV repetida para distinguir diferencias reales de ruido.